Anticipar la deserci n escolar en los municipios de Colombia

Proyecto 2 y 3 An lisis, limpieza y modelado Introducci n a la ciencia de los datos

Prof. H ctor Fabio Ocampo Arbel ez Grupo 1 Juan Felipe Ruiz Jhorman Ricardo Loaiza Julian Andres Rojas
Juan Manuel Perez Octubre de 2026

1. Contexto del dataset y pregunta de negocio

Se trabaja con el mismo dataset del Proyecto 1: Estad sticas en educaci n preescolar, b sica y media por municipio del Ministerio de Educaci n Nacional (datos.gov.co), con 15.707 registros municipio-a o (1.122 municipios, 2011 2024) y 41 columnas: poblaci n de 5 a 16 a os, coberturas neta y bruta por nivel, y tasas de deserci n, aprobaci n, reprobaci n y repitencia.

Pregunta de negocio: qu caracter sticas de un municipio (cobertura, reprobaci n, repitencia, tama o, regi n e historial) permiten anticipar si tendr una deserci n escolar alta (> 5 %), para que el MEN y las Secretar as de Educaci n focalicen sus programas de permanencia antes de que los estudiantes abandonen?

Variable objetivo: ALTO_RIESGO_DESERCION = 1 si la deserci n supera el 5 % (unas 1,6 veces la mediana nacional), lo que da un problema de clasificaci n binaria desbalanceada (80 % / 20 %). Como complemento se estima la tasa continua (regresi n) y se segmentan los municipios con clustering.

2. An lisis exploratorio

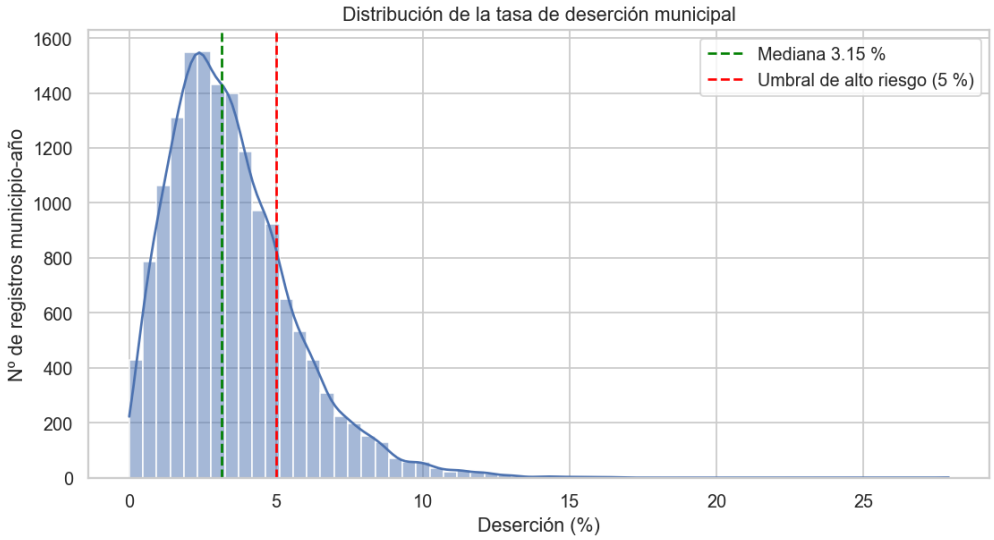


Figura 1. La deserci n es asim trica positiva: mediana 3,15 %, y el 20 % de los registros supera el 5 %.

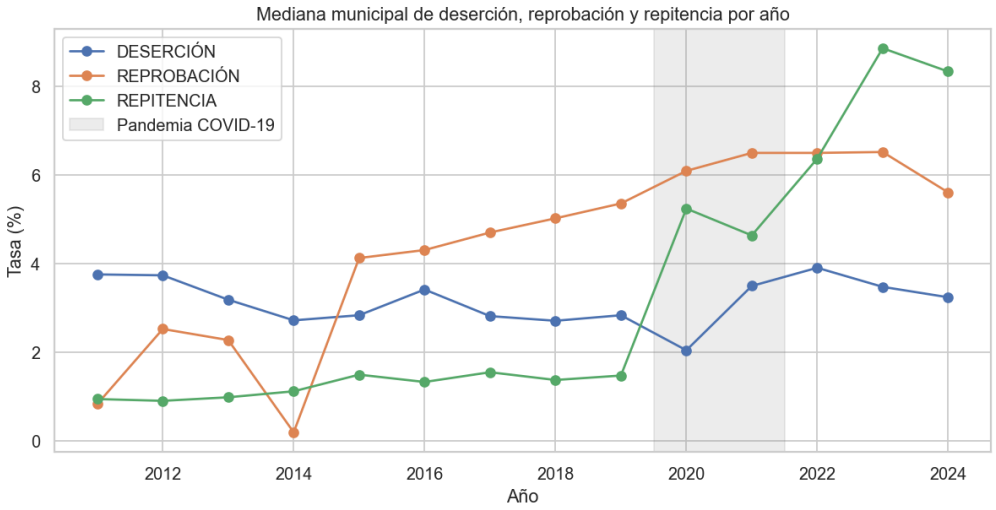


Figura 2. M nimo artificial en 2020 y rebote despu s; la repitencia se dispara desde la pandemia.

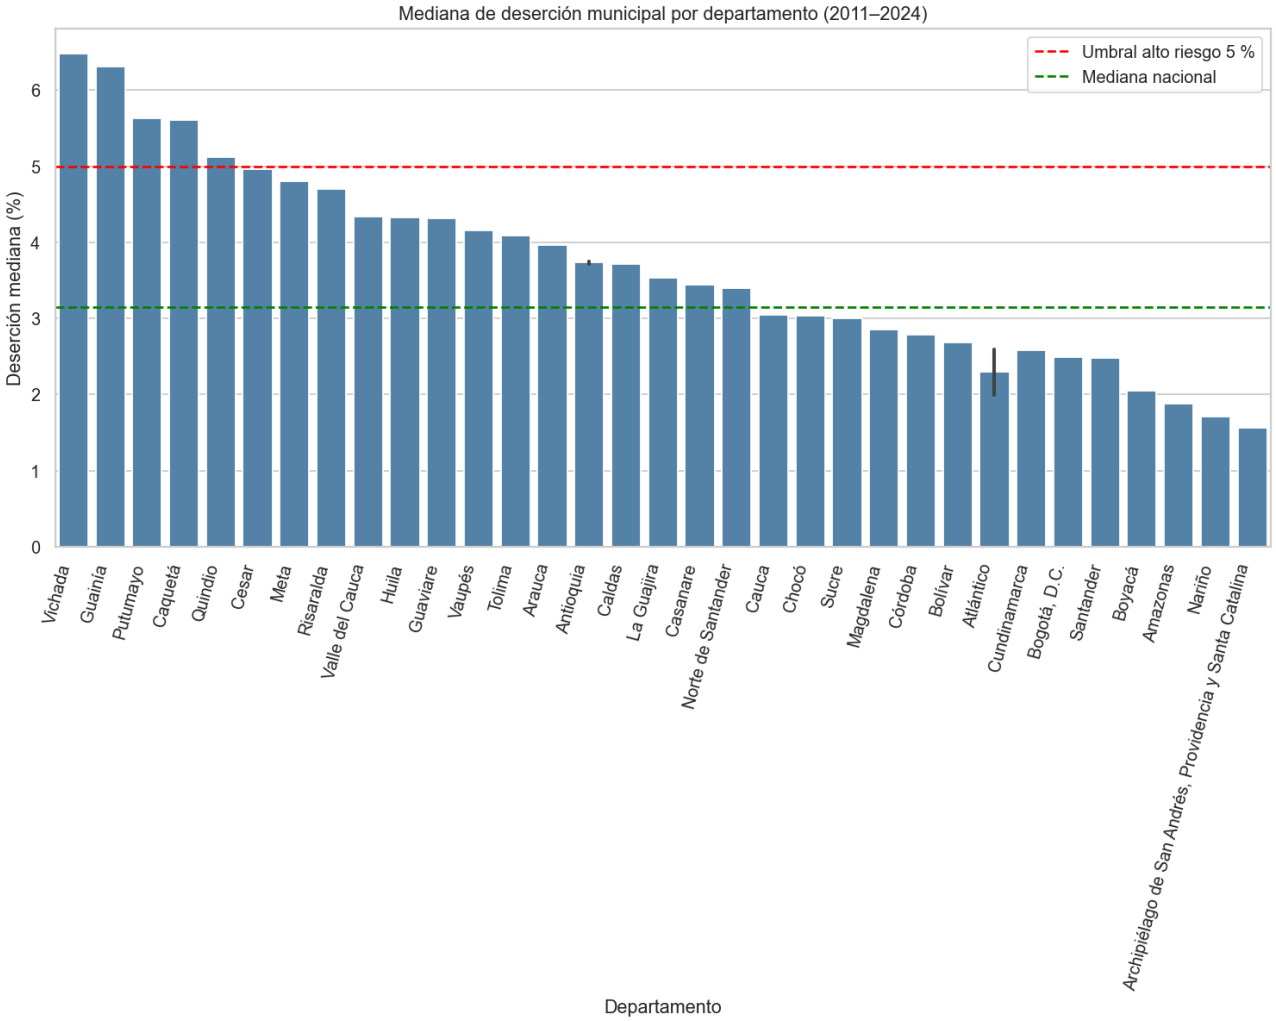


Figura 3. Vichada, Guain a, Putumayo y Caquet superan el umbral de riesgo en mediana.

Tres hallazgos clave

Problema concentrado y geogr fico: uno de cada cinco registros est en alto riesgo, y los casos m s graves se agrupan en la Amazon a y la Orinoqu a.

Huella de la pandemia: la deserci n toc un m nimo en 2020 (2,0 %) y rebot a 3,9 % en 2022; la repitencia pas de ~1,5 % a m s de 8 %.

Ninguna variable lo explica sola: las correlaciones con la deserci n son d biles (|r| < 0,25). La nica fuerte, con la aprobaci n (r = 0,54), es una identidad contable (aprobaci n + reprobaci n + deserci n = 100 %) y se excluy como predictor para evitar leakage. Spearman detecta una relaci n con el tama o del municipio (= 0,23) que Pearson no ve.

3. Limpieza y normalizaci n

El pipeline pasa de 15.707 filas crudas a 15.558 filas limpias y 59 columnas (datos_limpios.parquet). El hallazgo m s importante de la limpieza fue que la poblaci n de 2021 viene con punto como separador de miles ('1.148' = 1.148 ni os; '3.89' = 3.890). Una conversi n directa habr a dejado 925 municipios con ~3 habitantes y habr a desordenado el tama o de todos los municipios en ese a o. Las decisiones, con su justificaci n:

Problema	Decisi n	Por qu
C digos DANE sin cero inicial (1.776 filas)	Rellenar a 5/2 d gitos	Un mismo municipio aparec a con dos c digos.
POBLACI N 2021 con separador de miles	Parser propio ('3.89' 3.890)	Le do ingenuamente, 925 municipios quedaban con ~3 habitantes.
Filas NACIONAL, nombres duplicados	Eliminar / normalizar por c digo	El agregado nacional no es un municipio.
TAMA O_GRUPO y SEDES_INTERNET (~51 % nulos)	Eliminar columnas	Faltante estructural: no existen desde 2018.
DESERCI N nula (142)	Eliminar filas	No se imputa el objetivo.
POBLACI N nula (6)	Mediana del mismo municipio	La poblaci n cambia poco a o a a o.
Coberturas nulas (< 1 %)	KNN (k = 5) en el Pipeline	Muy correlacionadas (r 0.9). Se ajusta solo con train.
Reprobaci n / repitencia nulas	Mediana en el Pipeline	Sesgadas: la media se desplaza. Se ajusta solo con train.
Outliers (IQR)	Conservar	Son municipios reales y justo los que interesa detectar.
Asimetr a > 1 (9 variables)	log1p	Transformaci n fija: no aprende de los datos, sin leakage.
REGION, TIPO_ETC	One-Hot (drop_first)	Nominales: no tienen orden.
TAMA O_MUNICIPIO	Ordinal 0 3	Orden natural Muy peque o < < Grande.
Escala	StandardScaler en Pipeline	Se ajusta solo con train (evita leakage).

Se agreg una variable de historial, DESERCI N_A O_ANTERIOR (r = 0,46 con el objetivo). Se conoce antes de planear el a o siguiente, por lo que no es leakage; no se imputa cuando falta (2011), y por eso el modelado supervisado usa 2012 2024 (14.387 registros).

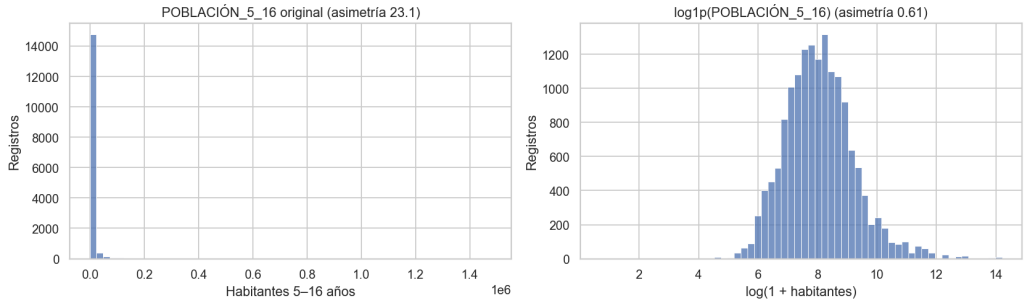


Figura 4. log1p reduce la asimetr a de la poblaci n de 23 a 0,6.

4. Modelos y comparaci n de desempe o

Se us un nico train_test_split 80/20, estratificado y con random_state = 42 para todos los modelos. La imputaci n (KNN y mediana) y el escalado van dentro de un Pipeline que se ajusta solo con train, de modo que las filas de test nunca influyen en el preprocesamiento; todas las

m tricas se calculan en test. Los hiperpar metros de KNN se eligieron con validaci n cruzada en train.

Clasificaci n: alto riesgo de deserci n (test, n = 2.878)

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	Tiempo e
Baseline (clase mayoritaria)	0.807	0.000	0.000	0.000	0.500	0.432
Regresi n log stica	0.720	0.375	0.674	0.482	0.785	0.523
KNN	0.818	0.551	0.300	0.389	0.741	23.880
Random Forest	0.826	0.578	0.358	0.442	0.802	3.712
Gradient Boosting	0.829	0.610	0.324	0.423	0.804	34.153

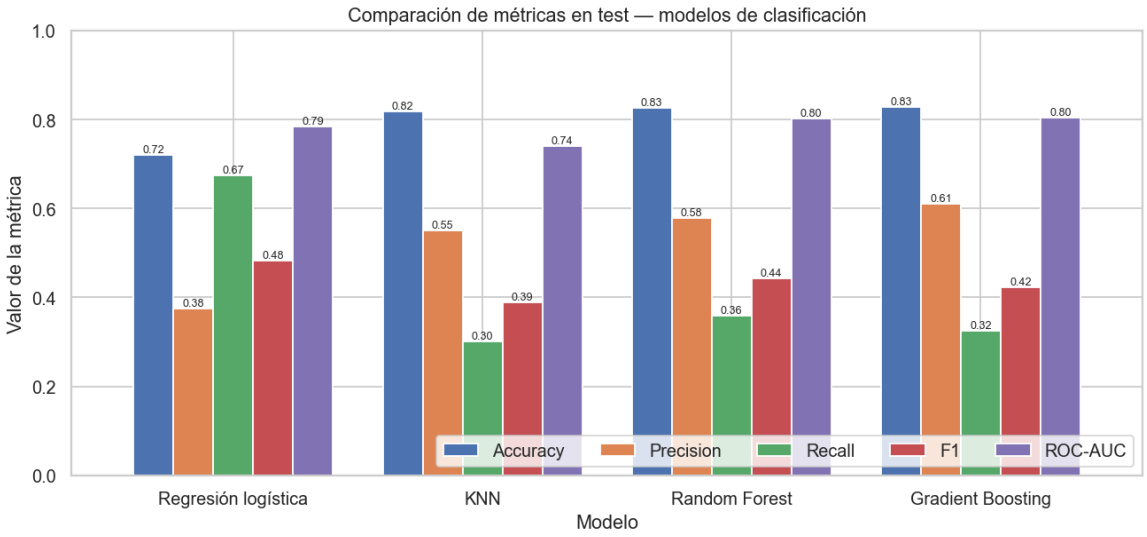


Figura 5. Comparaci n de m tricas en test.

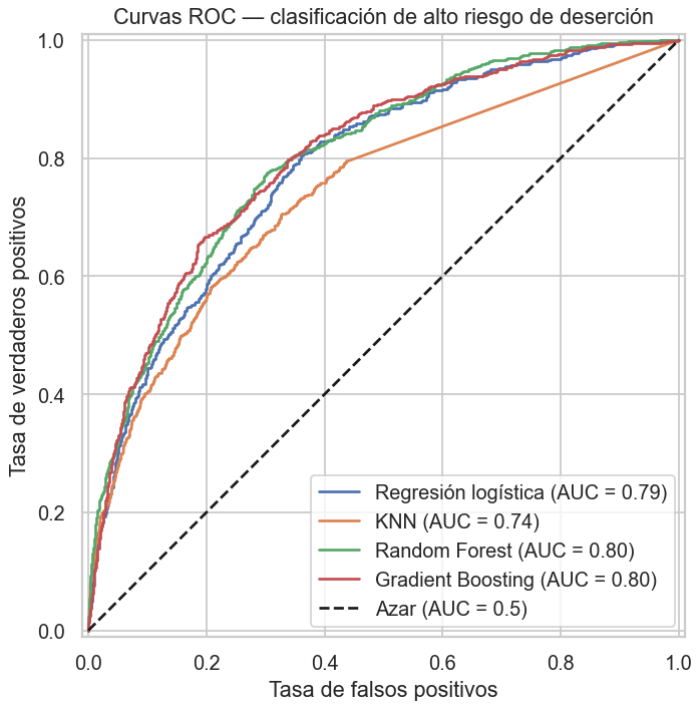


Figura 6. Random Forest y Gradient Boosting dominan la curva ROC (AUC 0,80).

Validaci n temporal: sirve para anticipar a os futuros?

El split aleatorio mezcla a os de un mismo municipio entre train y test, as que el modelo podr a apoyarse en patrones compartidos entre a os. Por eso se repiti la evaluaci n separando por

tiempo: cada modelo se entrena con 2012 2021, el umbral se elige en 2022 (validaci n) y, con el modelo reentrenado hasta 2022, se eval a una sola vez en 2023 2024. Ning n dato futuro toca el entrenamiento ni la elecci n del umbral.

Modelo	Umbral	Precision	Recall	F1	ROC-AUC
Regresi n log stica	0.520	0.376	0.873	0.525	0.846
KNN	0.140	0.260	0.906	0.404	0.750
Random Forest	0.390	0.414	0.811	0.548	0.834
Gradient Boosting	0.420	0.476	0.636	0.544	0.825

Los modelos no empeoran fuera del periodo de entrenamiento (AUC 0,75 0,85 frente a 0,74 0,80 en el split aleatorio): no depend an de recordar a cada municipio. Random Forest tiene el mejor F1 (0.55). La contrapartida es la precisi n (41%): hay unas 1,4 alertas falsas por cada acierto, aunque eso es 2,1 veces mejor que alertar al azar (19 %). Parte se explica porque 2022, el a o en que se eligi el umbral, fue un pico (30 % en riesgo), lo que vuelve al modelo m s alarmista. Si los recursos alcanzan para pocas visitas, el umbral puede subirse siguiendo la curva precisi n-recall.

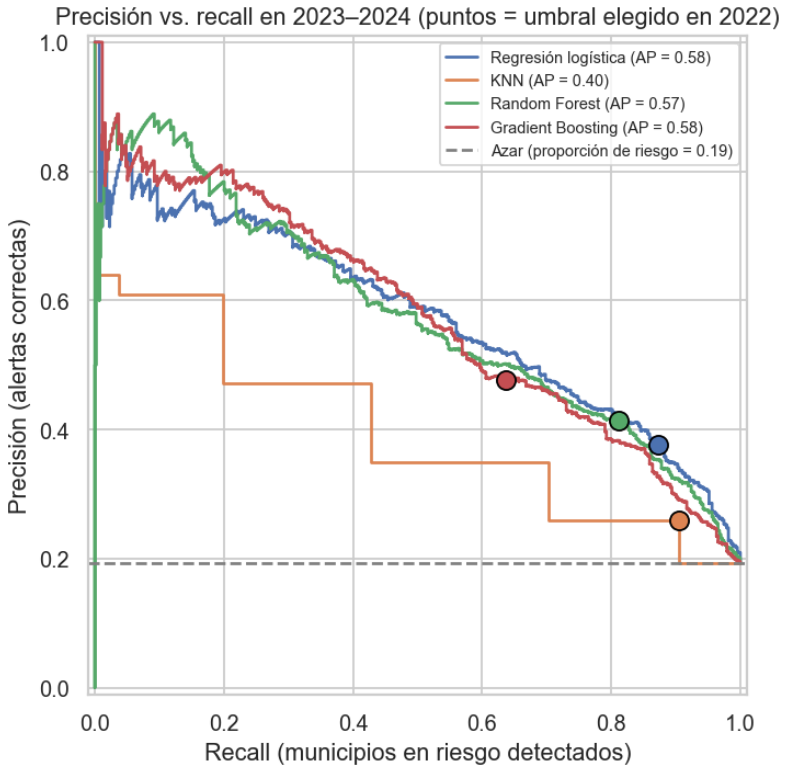


Figura 7. Precisi n vs. recall en 2023 2024; los puntos marcan el umbral elegido en 2022.

Umbral del modelo final en el split aleatorio. Con clases desbalanceadas, el umbral de 0,5 deja escapar a la mayor a de los municipios en riesgo. El umbral que maximiza F1 se eligi con validaci n cruzada dentro de train (0,36):

Variante	Accuracy	Precision	Recall	F1	ROC-AUC
RF umbral 0,50 test	0.826	0.578	0.358	0.442	0.802
RF umbral 0,36 test	0.786	0.458	0.581	0.512	0.802
RF umbral 0,39 2023 24 (temporal)	0.741	0.414	0.811	0.548	0.834

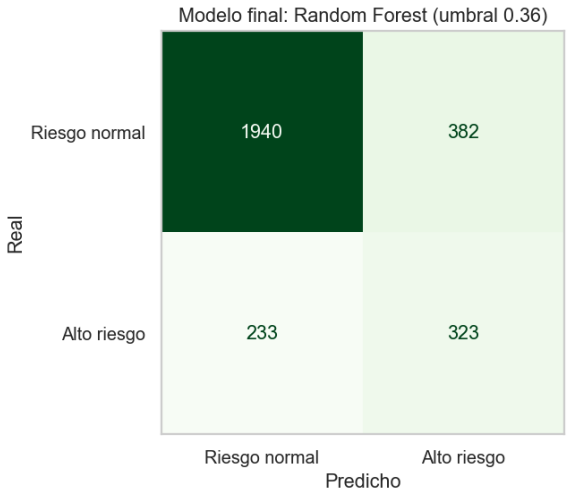


Figura 8. Matriz de confusi n del modelo final (Random Forest, umbral 0,36, test aleatorio).

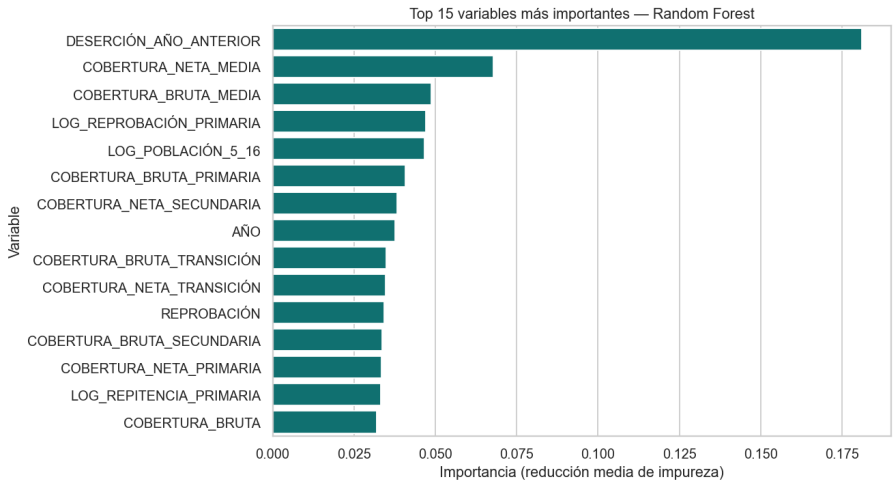


Figura 9. El historial de deserci n y la cobertura en educaci n media son los predictores m s importantes.

Regresi n complementaria: tasa de deserci n (%)

Modelo	MSE	RMSE	MAE	R
Regresi n lineal	3.439	1.855	1.317	0.280
Random Forest Regressor	3.202	1.789	1.266	0.329
Gradient Boosting Regressor	3.302	1.817	1.265	0.309

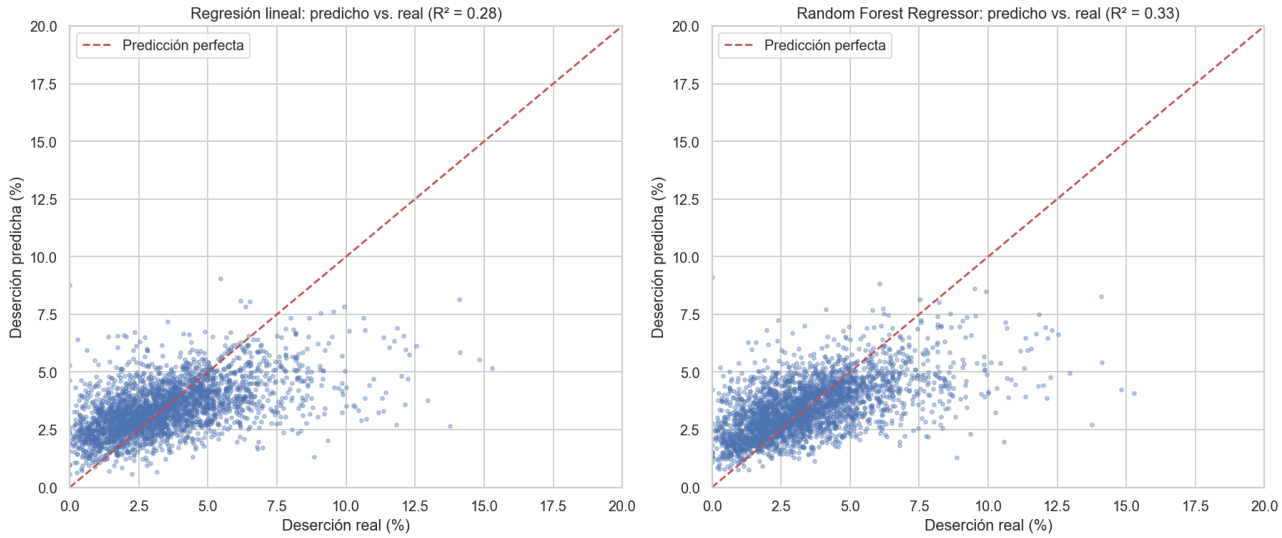


Figura 10. El modelo acierta en el rango t pico (2 6 %), pero subestima los casos extremos.

No supervisado: segmentaci n de municipios (2024)

Se us K-Means sobre 6 variables estandarizadas (cobertura neta total y de media, deserci n, reprobaci n, repitencia y tama o). k = 4 se eligi con el m todo del codo y Silhouette (el de k = 2 es apenas mayor, pero no sirve para focalizar). K-Means super al jer rquico de Ward:

Modelo	Silhouette	Davies-Bouldin
K-Means (k=4)	0.186	1.582
Jer rquico Ward (k=4)	0.115	1.809

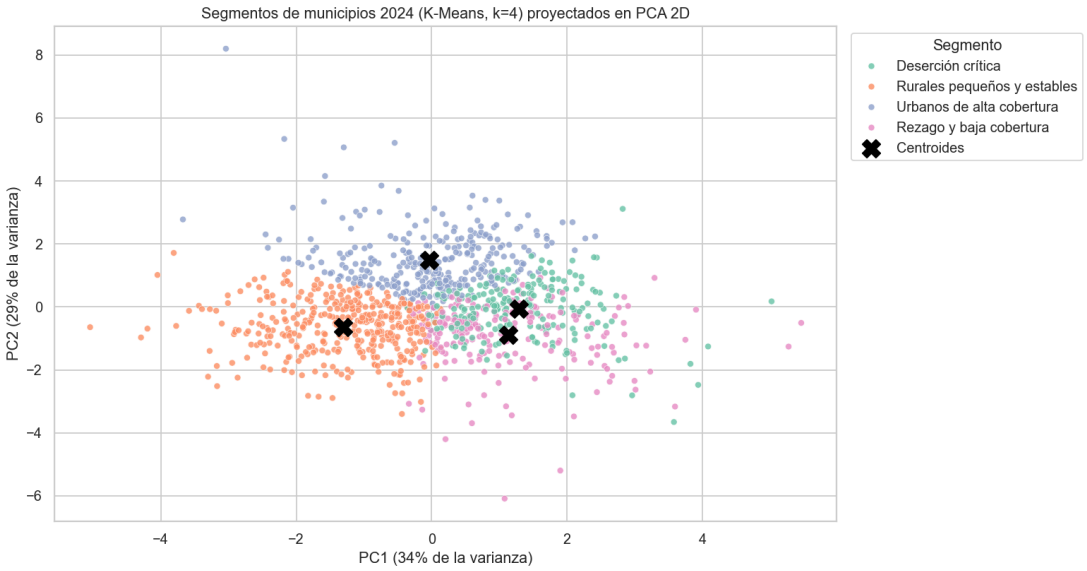


Figura 11. Segmentos proyectados en PCA 2D (63 % de la varianza): fronteras difusas, Silhouette 0,19.

Segmento	N	Perfil	Acci n
Deserci n cr tica	216	Cobertura aceptable, pero el 75 % en alto riesgo (Palmira, Tulu , Florencia).	Prioridad 1: permanencia, alimentaci n, transporte.
Rurales peque os y estables	390	Peque os, andinos, deserci n y reprobaci n bajas.	Mantener y replicar pr cticas.
Urbanos de alta cobertura	303	Capitales: cobertura neta 95 %, deserci n moderada.	Focalizar por barrios; reto de calidad.
Rezago y baja cobertura	212	Peor acceso y m s repitencia; deserci n reportada baja (Tumaco, Buenaventura).	Ampliar oferta de media y nivelar.

Cluster an malo: el segmento Rezago y baja cobertura tiene el peor acceso, pero una deserci n baja. Lo m s probable es que los j venes que abandonar an ni siquiera se matriculan, o que haya subregistro; all , una deserci n baja no es una buena noticia.

5. Conclusiones y posibles mejoras

Modelo elegido: Random Forest

Precisi n: el mejor F1 en ambos protocolos: 0.51 en el test aleatorio (umbral 0,36) y 0.55 al predecir 2023 2024 (umbral 0,39, AUC 0.83, recall 81%).

Interpretabilidad: sus importancias se explican en lenguaje de negocio: historial, cobertura en media, reprobaci n y tama o.

Velocidad: entrena en ~4 s, frente a ~34 s de Gradient Boosting con el mismo AUC, y no necesita escalado.

Efectividad real: detecta 58% de los municipios en riesgo en el test aleatorio y 81% en 2023 2024. De cada 10 alertas, unas 4 son casos reales (precisi n 41% 46%, unas 2 veces mejor que al azar): sirve como alerta temprana para priorizar visitas, no como diagn stico definitivo.

Hallazgos por etapa

An lisis: la deserci n es persistente, geogr fica y marcada por la pandemia.

Limpieza: los errores de formato (separador de miles, c digos sin cero inicial) ten an m s impacto que los nulos. Identificar la identidad aprobaci n + reprobaci n + deserci n evit un modelo enga osamente perfecto.

Modelado: clasificar el riesgo (AUC 0,80 en el test aleatorio y 0,83 en a os futuros) funciona mejor que estimar la tasa exacta (R 0,33). Los clusters muestran dos problemas distintos: municipios que pierden estudiantes y municipios que no logran incorporarlos.

Posibles mejoras

M s datos: unir variables socioecon micas (pobreza multidimensional, ruralidad, conflicto armado, migraci n venezolana) y resultados Saber 11 por municipio, que explicar an los casos extremos.

M s features: m s rezagos (2 3 a os), la tendencia de la deserci n y el cambio en la matr cula.

Hiperpar metros: b squeda con GridSearch/Optuna para Random Forest y Gradient Boosting, y calibraci n de probabilidades.

Otros algoritmos: XGBoost/LightGBM, y validaci n temporal con varios cortes (TimeSeriesSplit) en lugar de uno solo.

Umbral seg n capacidad: elegir el umbral con el n mero de visitas que el MEN pueda hacer (curva precisi n-recall), en lugar de maximizar F1 en un solo a o que adem s fue at pico (2022).