# ¿Podemos anticipar la deserción escolar?

Proyecto 2 y 3 — Análisis, limpieza y modelado de datos del MEN (2011–2024)

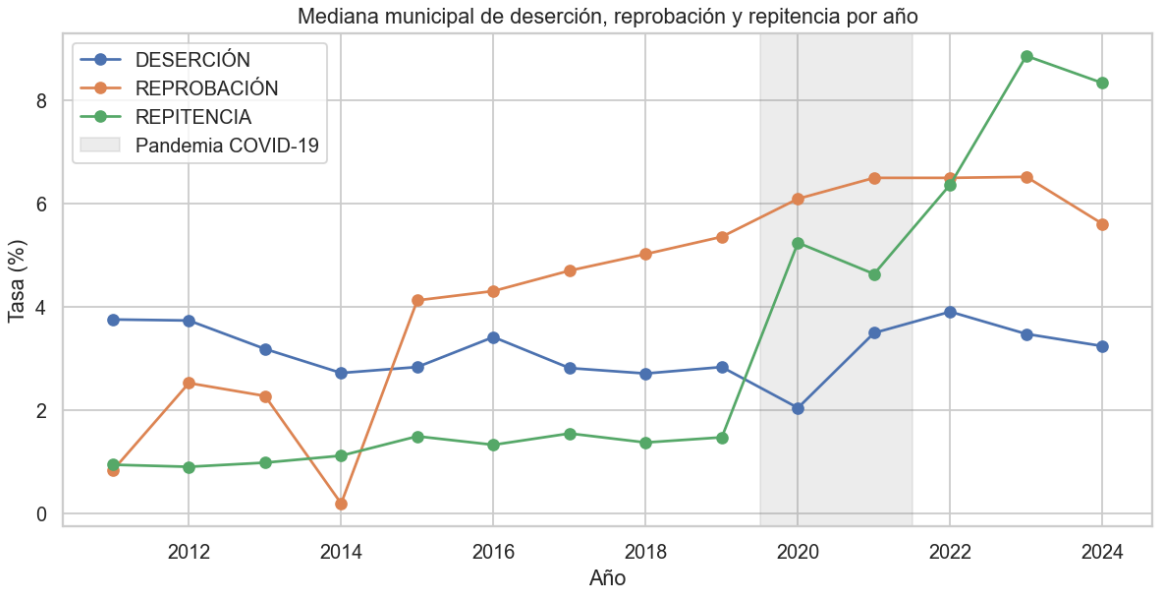
Grupo 1 — Juan Felipe Ruiz · Jhorman Ricardo Loaiza · Julian Andres Rojas · Juan Manuel Perez

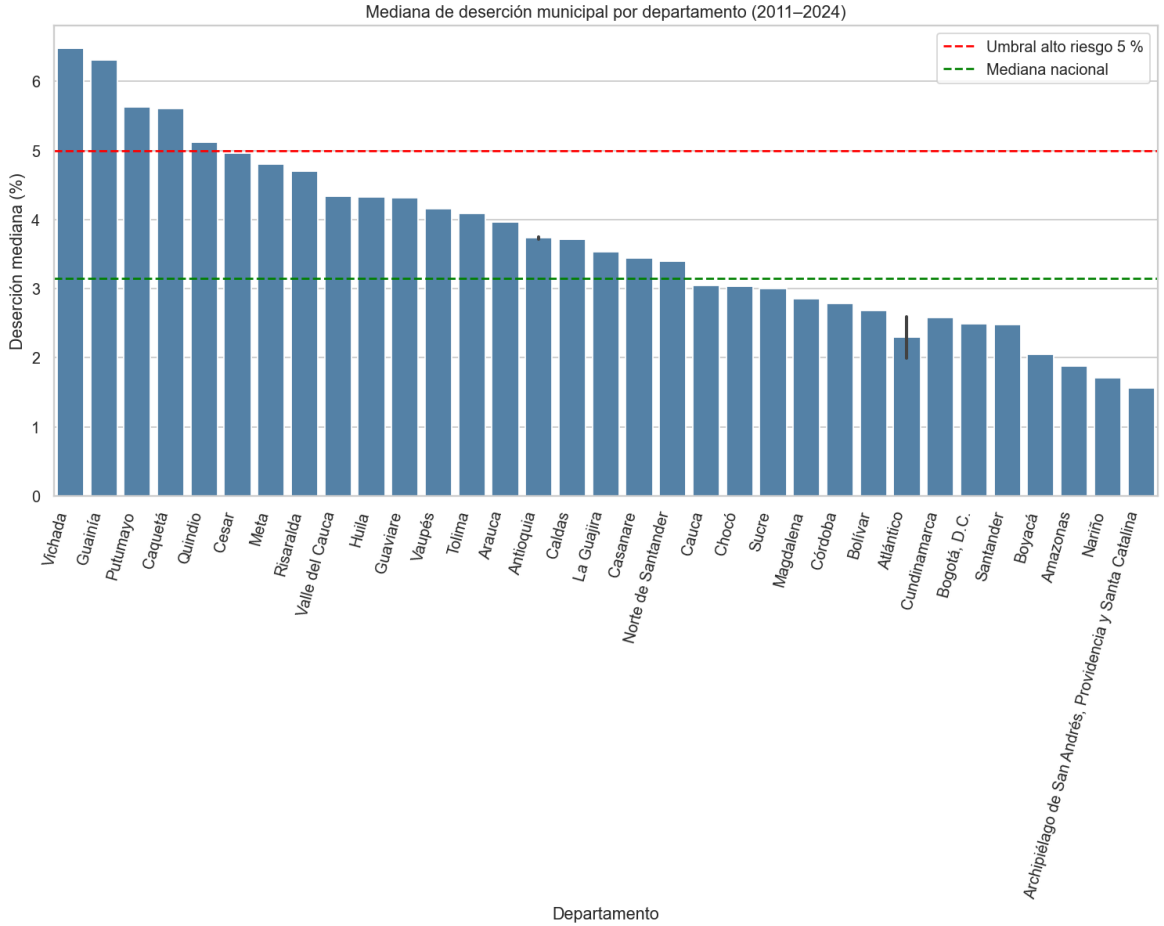
Introducción a la ciencia de los datos · Prof. Héctor Fabio Ocampo Arbeláez

# Pregunta de negocio

- Dataset: el mismo del P1. Estadísticas del MEN por municipio: 15.707 registros, 1.122 municipios, 2011–2024.
- Pregunta: ¿qué características de un municipio permiten anticipar una deserción alta (> 5 %)?
- Para qué: que el MEN y las Secretarías focalicen sus programas de permanencia antes de que los estudiantes se vayan.
- Objetivo: clasificación binaria desbalanceada (80/20) + regresión de la tasa + segmentación (clustering).

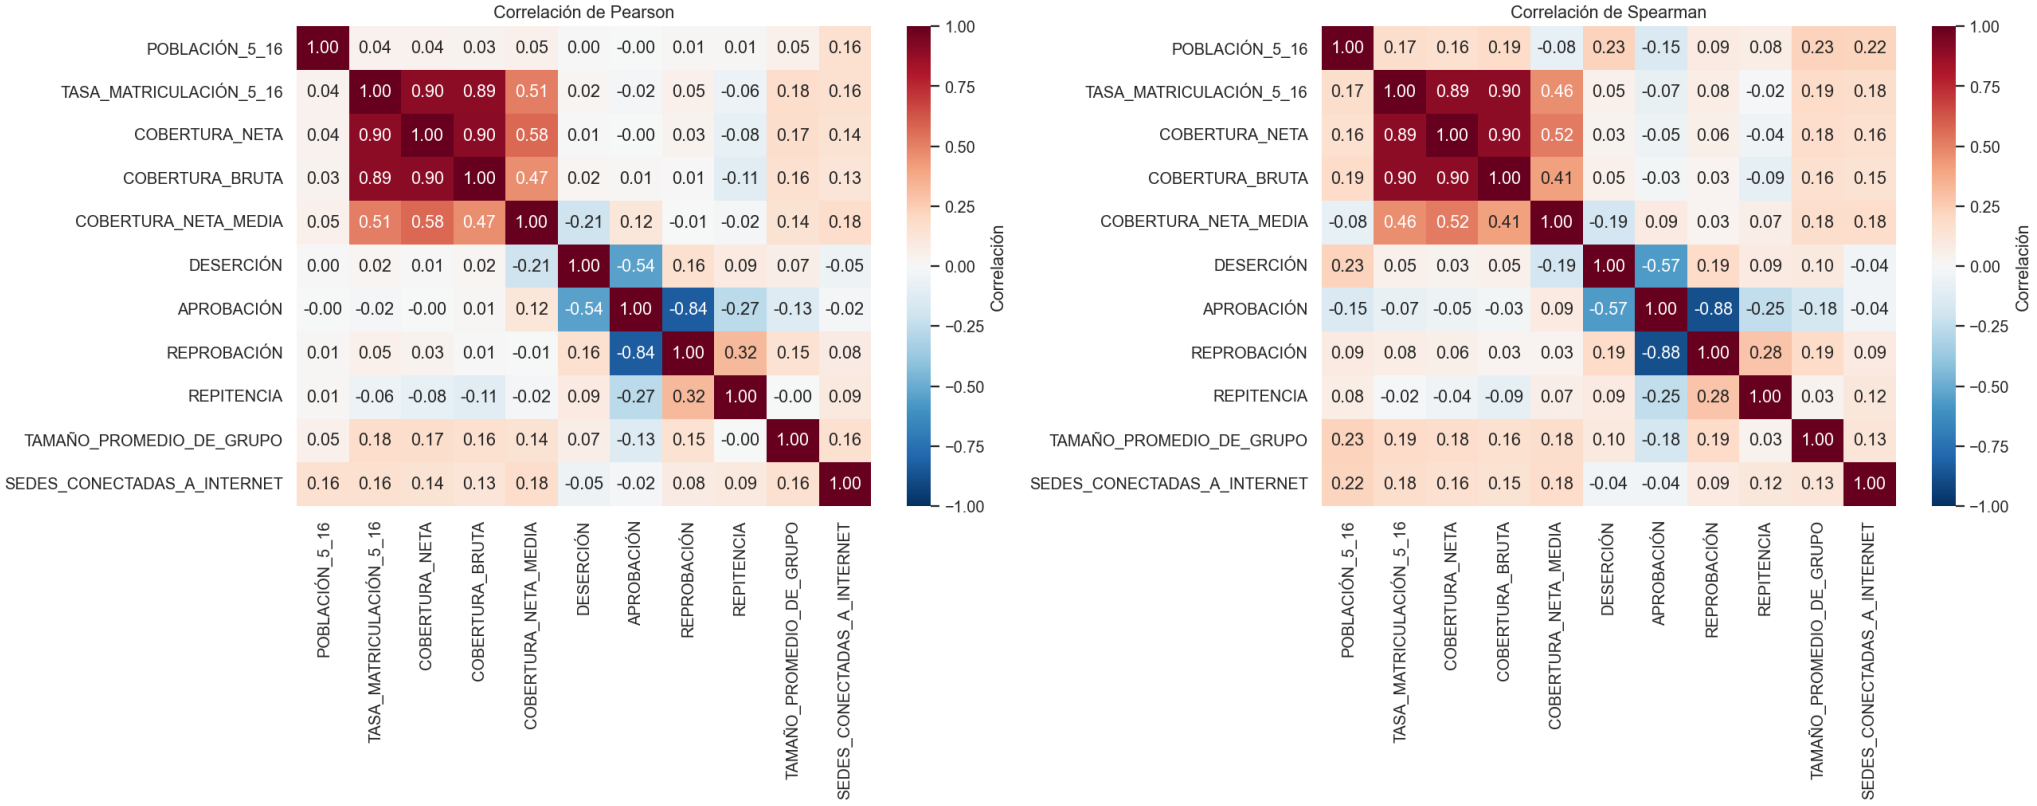
# EDA: un problema concentrado y marcado por la pandemia




• Mínimo en 2020 y rebote después; la repitencia pasa de 1,5 % a 8 %. · Amazonía y Orinoquía por encima del 5 %.

# EDA: ninguna variable lo explica sola (y una trampa)

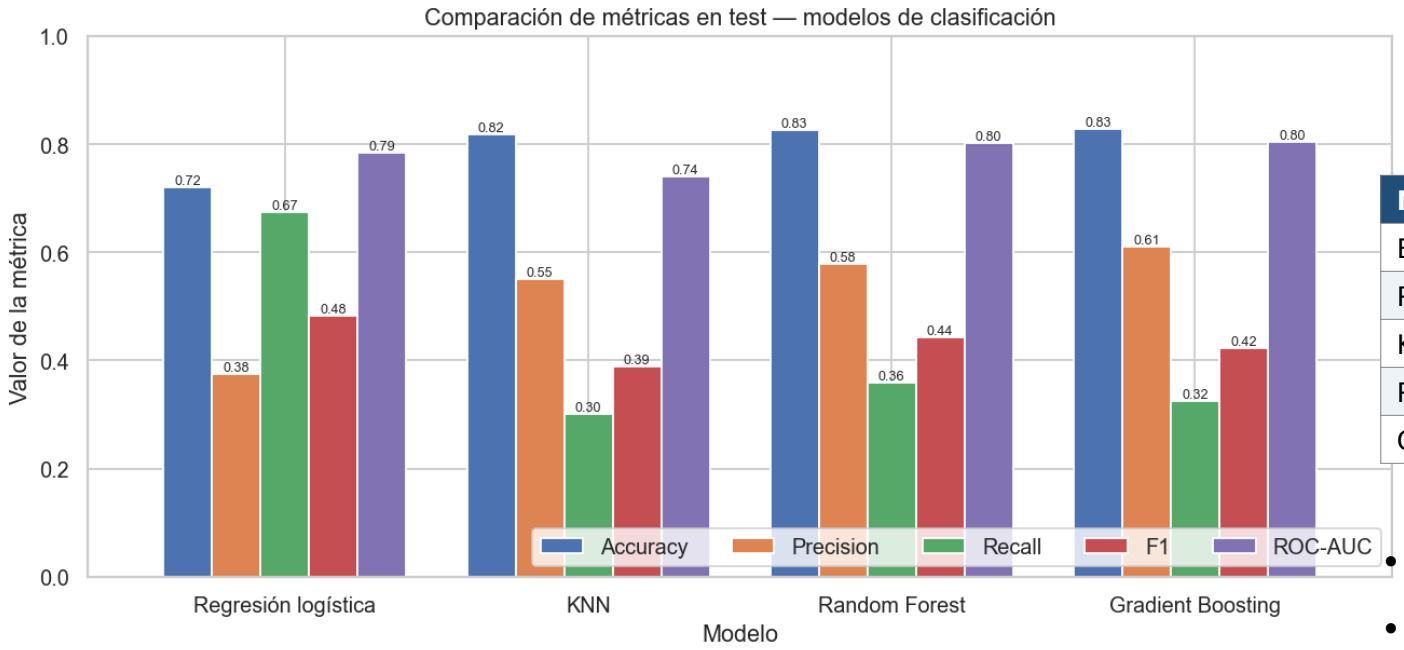



- |r| < 0,25 con todas las variables, excepto la aprobación (−0,54): aprobación + reprobación + deserción = 100 %, así que es leakage y se excluye.
- Spearman revela la relación con el tamaño del municipio (ρ = 0,23) que Pearson oculta → conviene usar modelos no lineales.

# Limpieza: lo que habría arruinado el análisis

- POBLACIÓN 2021 con separador de miles: '3.89' = 3.890 niños, no 3,89 (925 municipios afectados).
- Códigos DANE sin cero inicial (1.776 filas) → un municipio partido en dos. Se eliminan las filas NACIONAL y se unifican los nombres.
- Nulos: se eliminan 2 columnas vacías desde 2018 y el objetivo nulo; población con la mediana del municipio. KNN (coberturas) y mediana (tasas) dentro del Pipeline, ajustados solo con train.
- Outliers: se conservan, porque son los municipios que queremos detectar. Se usa log1p en 9 variables sesgadas.
- Encoding: One-Hot (región, tipo de ETC) y Ordinal (tamaño). StandardScaler dentro del Pipeline, después del split.
- Nueva variable: deserción del año anterior (historial conocido al momento de predecir).

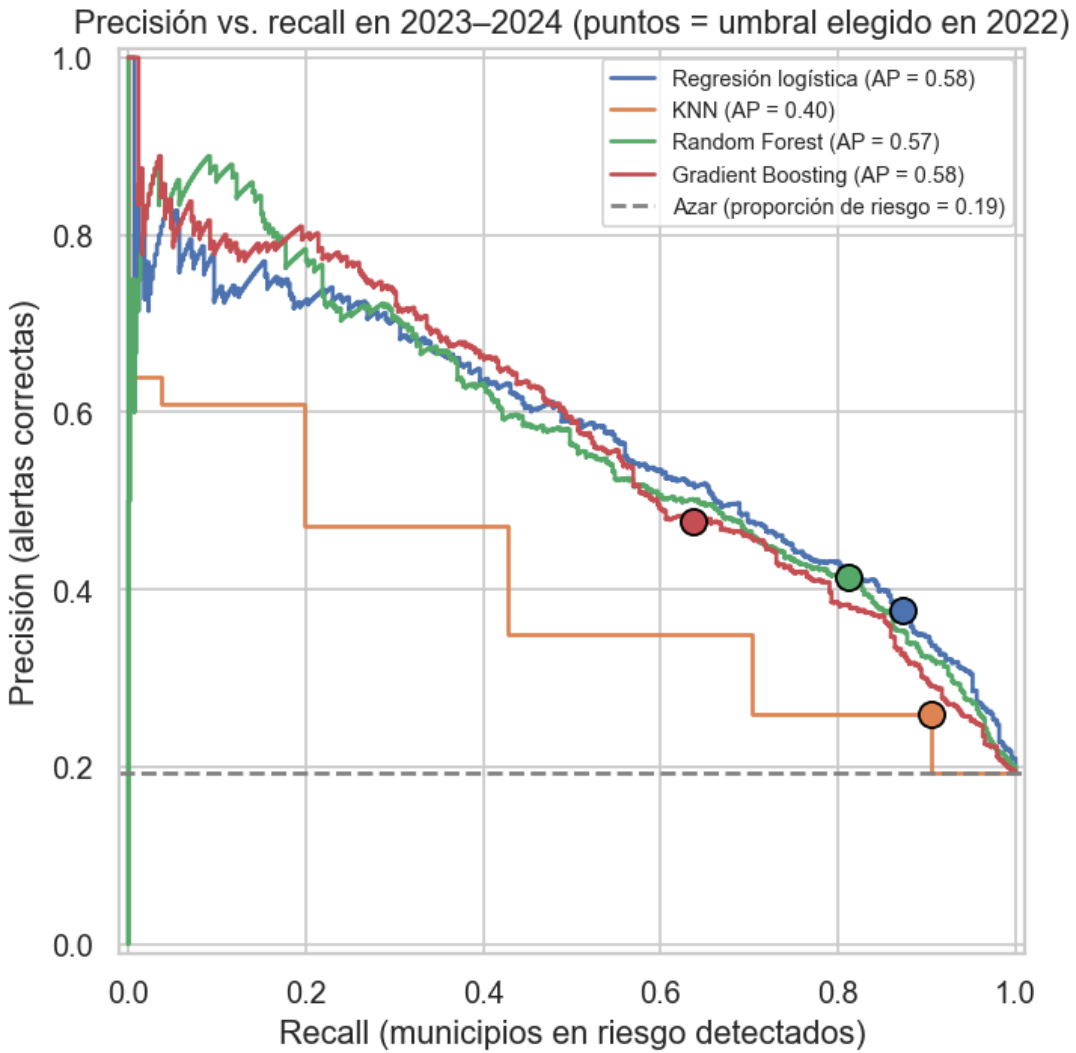
# Modelos supervisados: mismo split 80/20, métricas en test




| Modelo | Precision | Recall | F1 | ROC-AUC |
|---|---|---|---|---|
| Baseline (clase mayoritaria) | 0.000 | 0.000 | 0.000 | 0.500 |
| Regresión logística | 0.375 | 0.674 | 0.482 | 0.785 |
| KNN | 0.551 | 0.300 | 0.389 | 0.741 |
| Random Forest | 0.578 | 0.358 | 0.442 | 0.802 |
| Gradient Boosting | 0.610 | 0.324 | 0.423 | 0.804 |

- Todos superan al baseline (F1 = 0).
- Los árboles ordenan mejor el riesgo (AUC 0,80); la logística detecta más casos, pero con muchas falsas alarmas.

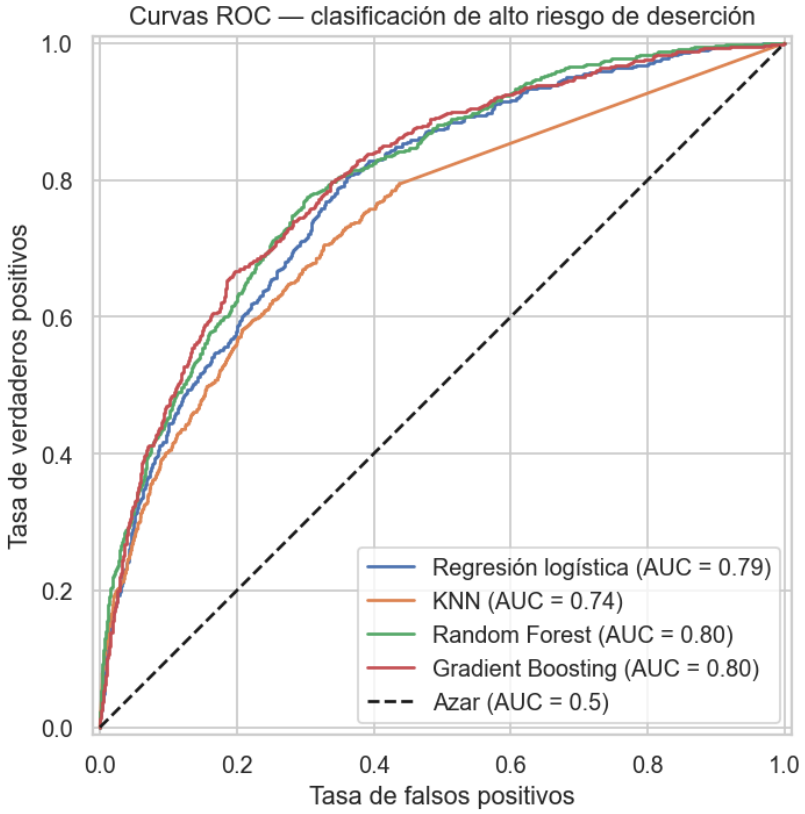
# Validación temporal: ¿anticipa años futuros?

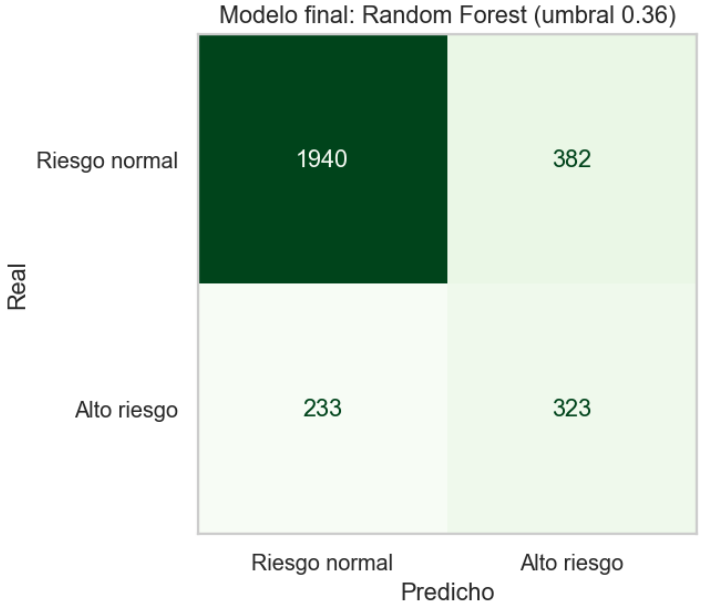



| Modelo | Umbral | Precision | Recall | F1 | ROC-AUC |
|---|---|---|---|---|---|
| Regresión logística | 0.520 | 0.376 | 0.873 | 0.525 | 0.846 |
| KNN | 0.140 | 0.260 | 0.906 | 0.404 | 0.750 |
| Random Forest | 0.390 | 0.414 | 0.811 | 0.548 | 0.834 |
| Gradient Boosting | 0.420 | 0.476 | 0.636 | 0.544 | 0.825 |

- Entrena con 2012–2021, elige el umbral en 2022 y evalúa una sola vez en 2023–2024, sin que ningún dato futuro toque el entrenamiento.
- Los modelos no empeoran (AUC hasta 0.85): no dependían de recordar a cada municipio.
- Costo: precisión de 41%, es decir ~1,4 alertas falsas por acierto (2,1 veces mejor que al azar). 2022 fue un año pico, y el umbral se puede subir según los recursos.

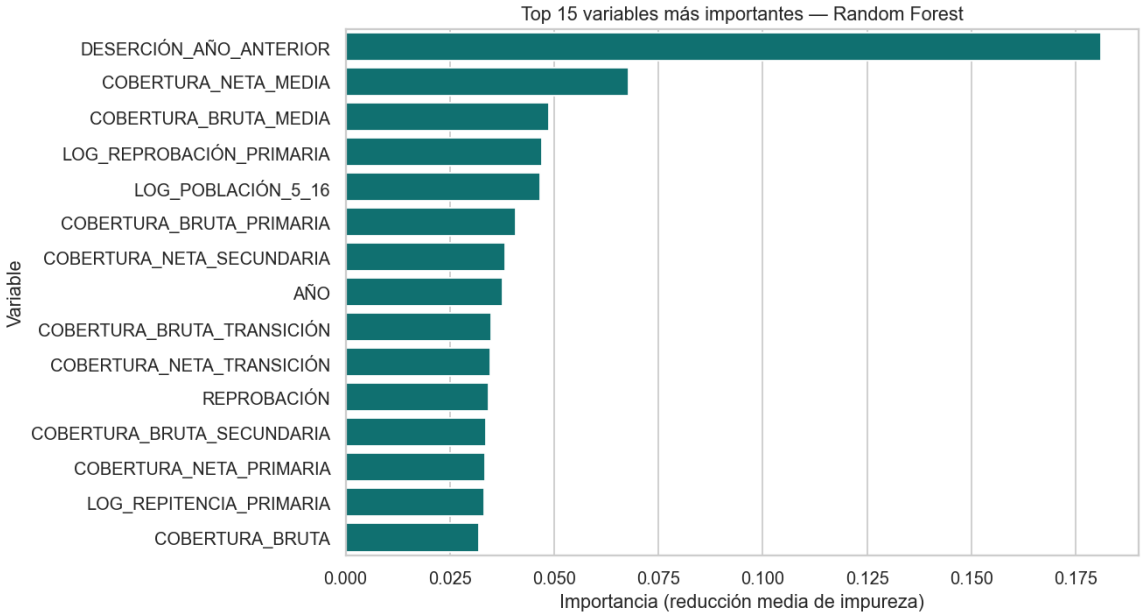
# Modelo final: Random Forest

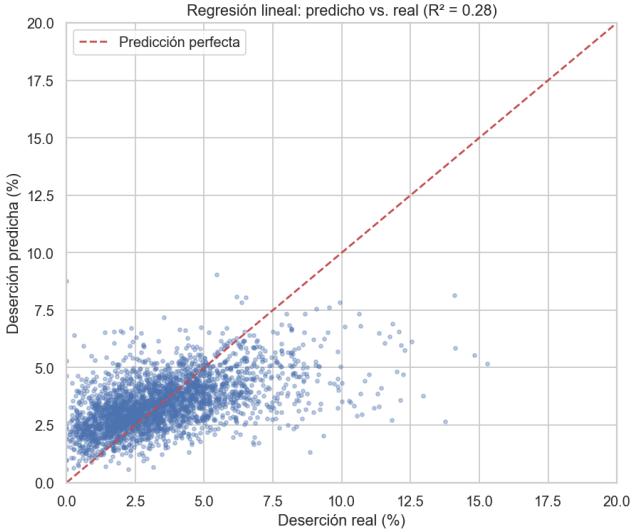


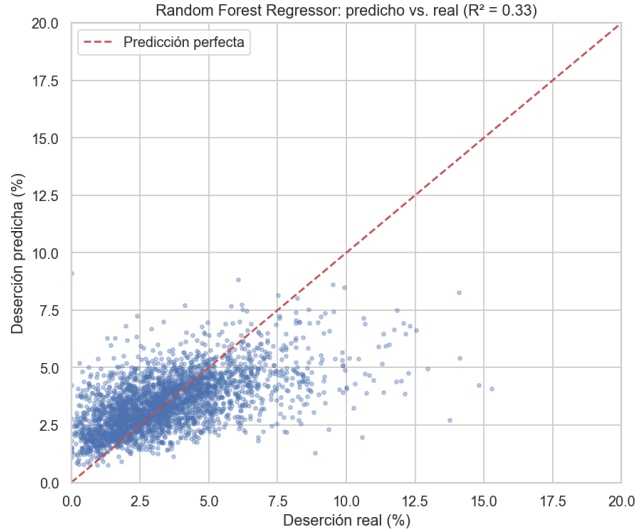




- Umbral 0,36 elegido con CV en train: el F1 pasa de 0.44 a 0.51, y el recall de 36% a 58%.
- Validación temporal (umbral 0,39 elegido en 2022, prueba 2023–24): F1 0.55, AUC 0.83, recall 81%.
- Mejor F1 en ambos protocolos, interpretable y unas 10 veces más rápido que Gradient Boosting.

# ¿Qué predice el riesgo? · ¿Y la tasa exacta?

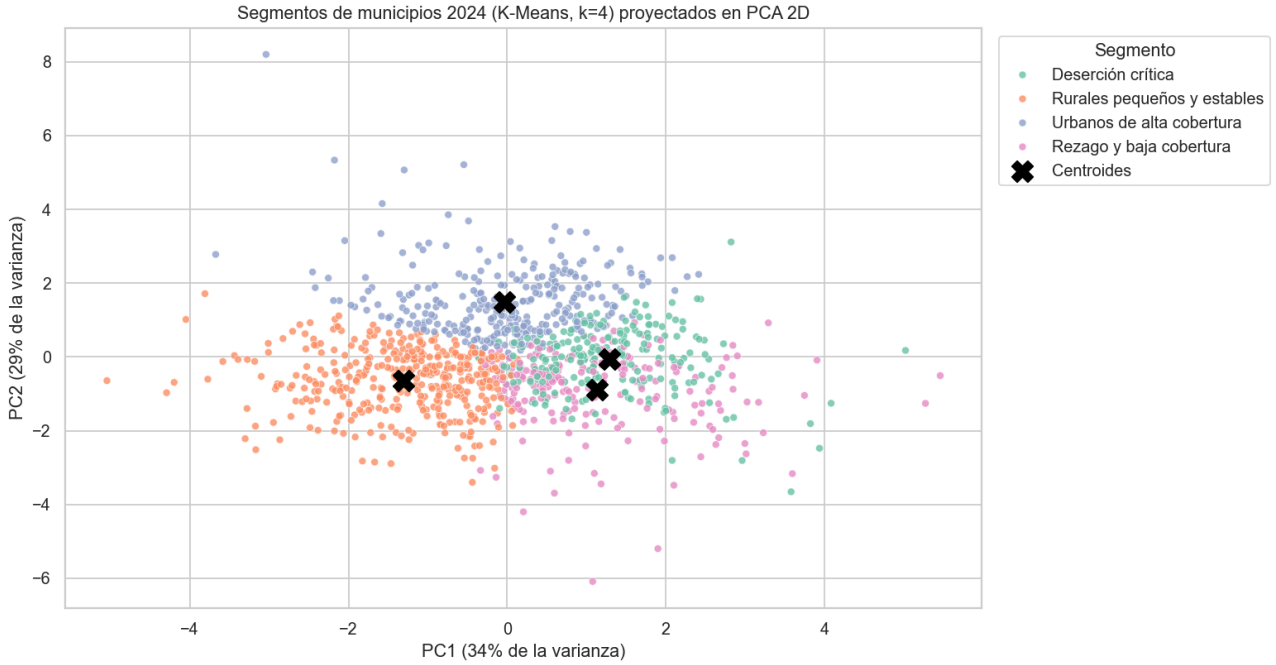



- El historial de deserción y la cobertura en educación media son los predictores que más pesan.
- Regresión: $R^2 = 0.33$ y MAE = 1.26 puntos porcentuales. Subestima los casos extremos, por eso es mejor clasificar el riesgo.

# Segmentación de municipios 2024 (K-Means, k = 4)




| Segmento | N | Perfil | Acción |
|---|---|---|---|
| Deserción crítica | 216 | Cobertura aceptable, pero el 75 % en alto riesgo (Palmira, Tuluá, Florencia). | Prioridad 1: permanencia, alimentación, transporte. |
| Rurales pequeños y estables | 390 | Pequeños, andinos, deserción y reprobación bajas. | Mantener y replicar prácticas. |
| Urbanos de alta cobertura | 303 | Capitales: cobertura neta 95 %, deserción moderada. | Focalizar por barrios; reto de calidad. |
| Rezago y baja cobertura | 212 | Peor acceso y más repitencia; deserción reportada baja (Tumaco, Buenaventura). | Ampliar oferta de media y nivelar. |

- Silhouette 0.19 y Davies-Bouldin 1.58 (mejor que Ward): fronteras difusas.
- Anómalo: 'Rezago' tiene baja deserción porque los jóvenes ni siquiera se matriculan.

# Conclusiones y mejoras

• Se puede anticipar el riesgo con AUC ≈ 0,80 (test aleatorio) y 0,83 (2023–2024, sin datos futuros): sirve como alerta temprana para priorizar visitas, no como diagnóstico.

• Hay dos problemas distintos: municipios que pierden estudiantes y municipios que no los incorporan; cada uno necesita una política diferente.

• En la limpieza, los errores de formato pesaban más que los nulos; detectar la identidad contable evitó un modelo engañosamente perfecto.

## Mejoras

• Más datos: pobreza, ruralidad, conflicto, migración y Saber 11 por municipio. · Más features: rezagos de 2–3 años y tendencia.

• Optimizar hiperparámetros (GridSearch/Optuna), probar XGBoost/LightGBM y validar con varios cortes temporales (TimeSeriesSplit).